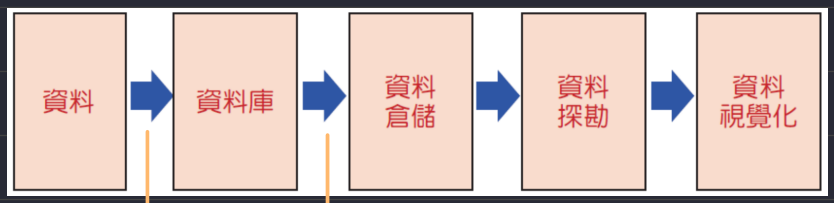
資料處理鏈（Data processing chain）

會考



→ 統整成一份大表格，集中所有資料

→ 將資料匯入的過程，例如：紙本到電子檔

資料倉儲 Data Warehouse

1. 主題式的（Subject Oriented）
2. 整合的（Integrate）
3. 穩定的（Non-Volatile）
4. 時變性（Time Variant）

組成的一個環境，是一個過程

→ 提供決策支援

資料 vs. 變數

資料（Data）：每個樣本個別的觀測變數值

變數（Variable）：每個樣本可以測量或是描述的特徵（獨立變數/相依變數）

觀測值（Observed value）：是指某一特定樣本所觀察或測量的數值

獨立變數：事件的原因

相依變數：原因所導致的結果

姓名	身高	體重	是否過重
Kathy	10cm	999kg	True

科學測量尺度的資料（類型）

名目資料　次序資料　區間資料　比值資料

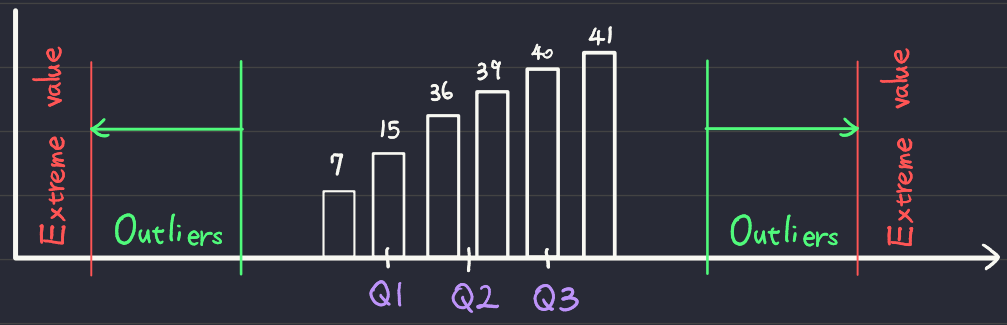
	Provides:	Nominal	Ordinal	Interval	Ratio
可排序	The “order” of values is known		✔	✔	✔
次數 / 分配頻率	“Counts,” aka “Frequency of Distribution”	✔	✔	✔	✔
眾數	Mode	✔	✔	✔	✔
中位數	Median		✔	✔	✔
平均數	Mean			✔	✔
可算差距	Can quantify the difference between each value			✔	✔
加減運算	Can add or subtract values			✔	✔
乘除運算	Can multiple and divide values				✔
絕對零點	Has “true zero”				✔

ex. 顏色　ex. 名次　ex. 溫度　ex. 身高

-10度 與 90度 差 -9 倍　測量不可以有負值

還有 二進位大型物件BLOB（Binary Large Objects）

分位數



四分位數 (Quantile)

$$Q_1(25\%) = 15 \qquad Q_2(50\%) = \frac{36+39}{2} = 37.5 \qquad Q_3(75\%) = 40$$

四分位距 (Interquartile range)

$$I_{QR} = Q_3 - Q_1 = 25$$

離群值/異常值 (Outliers)

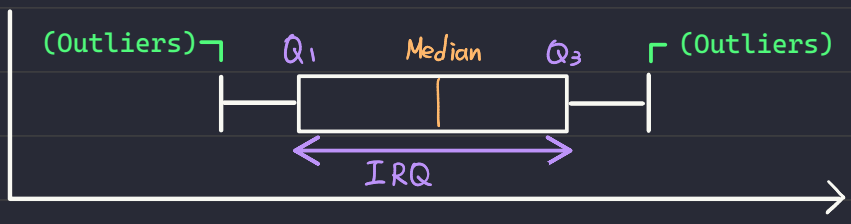
如果 x 在資料範圍內，且 $x < Q_1 - 1.5 \times IQR$ 或 $x > Q_3 + 1.5 \times IQR$

極端值 (Extreme value)

如果 x 在資料範圍內， $x < Q_1 - 3 \times IQR$ 或 $x > Q_3 + 3 \times IQR$

→ 應用時會捨棄這些資料樣本

箱形圖 (Box plot or box-and-whisker plot)



關聯式資料庫

實體關聯圖（Entity Relation Diagram, ER Diagram）

關係（Relation）

多對多（many to many）

Ex: 一個學生可以修習多門課程，而一個課程也可以有多名學生修習

一對多（one to many）

Ex: 一門課程只能由一個老師開設

資料庫正規化（normalization）：在不影響資料表示能力的情形下，減少表格個數

外來鍵（foreign key）: 表格中份其他表格的 key

課程

課程代號	課名	時間	教室	老師代號
C1	計算機概論	M2~M4	R101	T1
C2	資料庫系統	T6~T8	R321	T1
C3	微積分	F5~F8	R101	T1
C4	個體經濟	F5~F8	R202	T2
…	…	…	…	

修習

學號	課程代號	成績
S1	C1	A
S1	C2	B
S2	C1	A+
S2	C3	C–
…	…	…

結構化查詢語言（Structured Query Language, SQL）

SELECT	要顯示的結果屬性
FROM	查詢處理時會用到的表格（關聯）
WHERE	查詢條件

關聯表綱要（relation schema）

老師	<u>老師代號</u>，姓名，性別>
學生	<u>學號</u>，姓名，性別，系別>
課程	<u>課程代號</u>，課名，時間，教室，老師代號>
修習	<u>學號</u>，<u>課程代號</u>，成績>

結構化 vs 非結構化資料

結構化資料：

編號	姓名	性別

一列資料稱作： 表一筆紀錄(record)，統計術語稱為觀測(observation)

一行資料叫做：特徵(characteristics)或變數(variable)

非結構化資料：

反正就不是資料庫，語音資料，視訊資料，表格和文字處理檔

NoSQL 資料庫

Pros：可以使用沒有結構的資料庫儲存大量資料

Cons：社群比MySQL差，效能較慢