


會考

資料處理鏈 (Data processing chain)



資料倉儲 Data Warehouse

1. 主題式的 (Subject Oriented) → 組成的一個環境，是一個過程
2. 整合的 (Integrate) → 提供決策支援
3. 穩定的 (Non-Volatile)
4. 時變性 (Time Variant)

資料 vs. 變數

資料 (Data)：每個樣本個別的觀測變數值

變數 (Variable)：每個樣本可以測量或是描述的特徵 (獨立變數/相依變數)

觀測值 (Observed value)：是指某一特定樣本所觀察或測量的數值

獨立變數：事件的原因

相依變數：原因所導致的結果

姓名	身高	體重	是否過重
Kathy	10cm	999kg	True

科學測量尺度的資料 (類型)

名目資料

次序資料

區間資料

比值資料

	Provides:	Nominal	Ordinal	Interval	Ratio
可排序	The "order" of values is known		✓	✓	✓
次數 / 分配頻率	"Counts," aka "Frequency of Distribution"	✓	✓	✓	✓
眾數	Mode	✓	✓	✓	✓
中位數	Median		✓	✓	✓
平均數	Mean			✓	✓
可算差距	Can quantify the difference between each value			✓	✓
加減運算	Can add or subtract values			✓	✓
乘除運算	Can multiple and divide values				✓
絕對零點	Has "true zero"				✓

ex. 顏色

ex. 名次


ex. 溫度

ex. 身高

還有 二進位大型物件 BLOB (Binary Large Objects)

-10度 與 90度 差 -9 倍 測量不可以有負值

分位數



四分位數 (Quantile)

$$Q_1(25\%) = 15 \quad Q_2(50\%) = \frac{36 + 39}{2} = 37.5 \quad Q_3(75\%) = 40$$

四分位距 (Interquartile range)

$$I_{QR} = Q_3 - Q_1 = 25$$

離群值/異常值 (Outliers)

如果 x 在資料範圍內, 且 $x < Q_1 - 1.5 \times IQR$ 或 $x > Q_3 + 1.5 \times IQR$

極端值 (Extreme value)

如果 x 在資料範圍內, $x < Q_1 - 3 \times IQR$ 或 $x > Q_3 + 3 \times IQR$

→ 應用時會捨棄這些資料樣本

箱形圖 (Box plot or box-and-whisker plot)



關聯式資料庫

實體關聯圖 (Entity Relation Diagram, ER Diagram)

關係 (Relation)

多對多 (many to many)

Ex: 一個學生可以修習多門課程，而一個課程也可以有多名學生修習

一對多 (one to many)

Ex: 一門課程只能由一個老師開設

資料庫正規化 (normalization): 在不影響資料表示能力的情形下，減少表格個數

外來鍵 (foreign key): 表格中份其他表格的 key

課程					修習		
課程代號	課名	時間	教室	老師代號	學號	課程代號	成績
C1	計算機概論	M2-M4	R101	T1	S1	C1	A
C2	資料庫系統	T6-T8	R321	T1	S1	C2	B
C3	微積分	F5-F8	R101	T1	S2	C1	A+
C4	個體經濟	F5-F8	R202	T2	S2	C3	C-
...	...	...	...		...	...	...

結構化查詢語言 (Structured Query Language, SQL)

SELECT	要顯示的結果屬性
FROM	查詢處理時會用到的表格 (關聯)
WHERE	查詢條件

關聯表綱要 (relation schema)

老師	<老師代號, 姓名, 性別>
學生	<學號, 姓名, 性別, 系別>
課程	<課程代號, 課名, 時間, 教室, 老師代號>
修習	<學號, 課程代號, 成績>

結構化 vs 非結構化資料

結構化資料：

編號	姓名	性別

—列資料稱作：表一筆紀錄(record)，統計術語稱為觀測(observation)

—行資料叫做：特徵(characteristics)或變數(variable)

非結構化資料：

反正就不是資料庫，語音資料，視訊資料，表格和文字處理檔

NoSQL 資料庫

Pros：可以使用沒有結構的資料庫儲存大量資料

Cons：社群比MySQL差，效能較慢