Regression（迴歸）

Linear Regression

Introduction

Use statistical technique to find relation between:

several independent variables （自變數：原因）

one dependent variable （應變數：結果）

Find a **best fitting curve** for a dependent variable in multidimensional space.

Use **coefficient of correlation** to measure the quality of fit

Correlations and Relationships

Population Standard Deviation（母體標準差） $\sigma = \sqrt{\frac{\sum_{i=1}^{N}(X_i-\mu)^2}{N}}$

→ 擁有整個資料的掌控權，e.g. 班上成績資料，此時的 μ 即為所有資料的平均數

Sample Standard Deviation（樣本標準差） $s = \sqrt{\frac{\sum_{i=1}^{n}(x_i-\bar{x})^2}{n-1}}$

→ 從大量資料中抽取部分作標準差，e.g. 全臺身高平均抽樣 1000 人

此時 $\bar{x}$ 為這 1000 人的平均，所以需要將分母 -1 降低 bias

Covariance（共變異數） $COV(x,y) = \frac{\sum(X_i-\bar{X})(Y_i-\bar{Y})}{n-1}$

→ 表現 x, y 是否有共同的變化趨勢

Correlation coefficient $r = \frac{COV(x,y)}{\sigma x \sigma y} = \frac{\sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i-\bar{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i-\bar{Y})^2}}$ $y \in$[-1, 1]

→ 為了消除單位的干擾，我們把 COV 除以兩者的標準差，結果落在 -1 ~ 1

Coefficient of Determination $R^2 = r^2$ $R^2 \in [0,1]$

→ 消去正負號

Sampling Error（抽樣誤差）

→ 今天抽 1 ~ 100 人平均身高 180cm, 明天抽 101 ~ 200 平均身高 182cm SST = 2

SST（Total Sum of Squares）（總變異） $SST = \sum(y_i - \bar{y})^2$ Variation of Mean（平均值的變異）

→ 如果你完全不打算寫任何演算法或畫線，單純用「平均值」去猜測每一個數據，你會產生的誤差總和。

SSR（Regression Sum of Squares）（迴歸平方和） $SSR = \sum(\hat{y}_i - \bar{y})^2$

→ 自從你畫了那條「擬合線」後，它比原本的「平均值」強了多少？

SSE（Error Sum of Squares）（殘差平方和） $SSE = \sum(y_i - \hat{y}_i)^2$ Variation of Fit（擬合的變異）

→ 「剩下的雜訊」，也就是你的 Noise（雜訊）

Variaience（變異數） $Var(X) = (\sigma x)^2$

Derivation of linear regresion equation

1. Let $\hat{y} = bx + a$
2. 求極值就微分=0，所以把式子整理後變成 $\beta = \frac{Cov(X,Y)}{Var(X)} = \frac{(\bar{XY} - \bar{X}\bar{Y})}{\bar{X_i^2} - \bar{X}^2}$
3. $\alpha = \bar{Y} - \beta\bar{X}$

$$R^2 = \frac{Var(mean) - Var(fit)}{Var(mean)} = \frac{SST - SSE}{SST}$$

Logistic Regression

Binomial Classifier　　(輸出為一個數值)

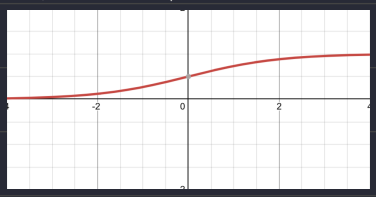
Odd (勝算比)

$$Odd = \frac{p}{1-p} = e^{f(x)}$$

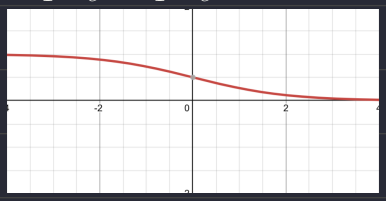
Sigmoid 函數

將 regression 的輸出值轉到 0 到 1 之間

$$\sigma(z) = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(\alpha+\beta x)}}$$



$$y = \frac{1}{1-e^{z}} = \frac{1}{1-e^{\alpha+\beta x}}$$



由於 $Odd = \frac{p}{1-p} = e^{f(x)}$ 所以 $ln(Odd) = a + \beta x$

Multinomial logistic classifier　　(輸出為一個 list, 裝載各自類別的數值)

Softmax function

$$\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_{j=1}^{K}\exp(z_j)} \qquad \text{softmax}(z) = \{p_1, p_2, p_3, p_4, ...\}$$

此為 sigmoid 的 generalize, 分別將各自的類別數值轉成機率