

Regression (迴歸)

Linear Regression

Introduction

Use statistical technique to find relation between:

several independent variables (自變數：原因)

one dependent variable (應變數：結果)

Find a **best fitting curve** for a dependent variable in multidimensional space.

Use **coefficient of correlation** to measure the quality of fit

Correlations and Relationships

Population Standard Deviation (母體標準差) $\sigma = \sqrt{\frac{\sum_{i=1}^N (X_i - \mu)^2}{N}}$

→ 擁有整個資料的掌控權，e.g. 班上成績資料，此時的 μ 即為所有資料的平均數

Sample Standard Deviation (樣本標準差) $s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$

→ 從大量資料中抽取部分作標準差，e.g. 全臺身高平均抽樣 1000 人

此時 $\bar{x}$ 為這 1000 人的平均，所以需要將分母 -1 降低 bias

Covariance (共變異數) $COV(x, y) = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{n-1}$

→ 表現 x, y 是否有共同的變化趨勢

Correlation coefficient $r = \frac{COV(x, y)}{\sigma_x \sigma_y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad y \in [-1, 1]$

→ 為了消除單位的干擾，我們把 COV 除以兩者的標準差，結果落在 -1 ~ 1

Coefficient of Determination $R^2 = r^2 \quad R^2 \in [0, 1]$

→ 消去正負號

Sampling Error (抽樣誤差)

→ 今天抽 1 ~ 100 人平均身高 180cm，明天抽 101 ~ 200 平均身高 182cm SST = 2

SST (Total Sum of Squares) (總變異) $SST = \sum (y_i - \bar{y})^2$ Variation of Mean (平均值的變異)

→ 如果你完全不打算寫任何演算法或畫線，單純用「平均值」去猜測每一個數據，你會產生的誤差總和。

SSR (Regression Sum of Squares) (迴歸平方和) $SSR = \sum (\hat{y}_i - \bar{y})^2$

→ 自從你畫了那條「擬合線」後，它比原本的「平均值」強了多少？

SSE (Error Sum of Squares) (殘差平方和) $SSE = \sum (y_i - \hat{y}_i)^2$ Variation of Fit (擬合的變異)

→ 「剩下的雜訊」，也就是你的 Noise (雜訊)

Variaience (變異數) $Var(X) = (\sigma x)^2$

Derivation of linear regression equation

1. Let $\hat{y} = bx + a$

2. 求極值就微分=0，所以把式子整理後變成 $b = \frac{Cov(X, Y)}{Var(X)} = \frac{(\bar{XY} - \bar{X}\bar{Y})}{\bar{X^2} - \bar{X}^2}$

3. $\alpha = \bar{Y} - \beta\bar{X}$

$$R^2 = \frac{Var(mean) - Var(fit)}{Var(mean)} = \frac{SST - SSE}{SST}$$

Logistic Regression

Binomial Classifier

(輸出為一個數值)


Odd (勝算比)

$$Odd = \frac{p}{1-p} = e^{f(x)}$$


Sigmoid 函數

將 regression 的輸出值轉到 0 到 1 之間

$$\sigma(z) = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(\alpha+\beta x)}}$$



$$y = \frac{1}{1-e^z} = \frac{1}{1-e^{\alpha+\beta x}}$$



由於 $Odd = \frac{p}{1-p} = e^{f(x)}$ 所以 $\ln(Odd) = \alpha + \beta x$

Multinomial logistic classifier

(輸出為一個 list, 裝載各自類別的數值)

Softmax function

$$\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_{j=1}^K \exp(z_j)} \quad \text{softmax}(z) = \{p_1, p_2, p_3, p_4, \dots\}$$

此為 sigmoid 的 generalize, 分別將各自的類別數值轉成機率